

# Klasifikasi Daun Tanaman Obat dengan Metode *Deep Learning*

Joy Kaihatu<sup>#</sup>, Edward Soenardi<sup>\*</sup>, Michael Adi Pratama<sup>#</sup>

<sup>#</sup>Universitas Kristen Petra

Jl. Siwalankerto No.121-131, Siwalankerto, Kec. Wonocolo, Surabaya, Jawa Timur 60236

**Abstract**— Daun tanaman obat sering digunakan sebagai media pengobatan alternatif. Banyak sekali penyakit yang dapat disembuhkan dengan mengkonsumsi daun tanaman obat, diantaranya yaitu diabetes, diare, maag, dan hipertensi. Namun, masyarakat masih kesulitan dalam mengenali jenis dan spesies daun tanaman obat, karena jumlahnya yang sangat banyak dan metode identifikasinya yang dilakukan secara konvensional. Berdasarkan permasalahan diatas, maka penelitian ini dilakukan untuk membantu masyarakat dalam mengenali jenis dan spesies daun tanaman obat. Klasifikasi daun tanaman obat pada penelitian ini dilakukan dengan cara membandingkan beberapa model Deep Learning. Model yang digunakan meliputi VGG16, VGG19, DenseNet201, InceptionV3, ResNet50V2, Xception, InceptionResnetV2, dan MobileNetV3. Dari hasil penelitian, didapatkan bahwa model Xception memiliki performa terbaik pada dataset train dengan akurasi mencapai 96.8 % dan model MobileNetV3 memiliki performa terbaik pada dataset val dengan akurasi mencapai 76.8 %.

**Keywords**— Daun Tanaman Obat, Deep Learning, Xception, MobileNetV3

## I. INTRODUCTION

Medicinal plant atau dikenal Tanaman Obat dalam bahasa indonesia telah lama menjadi sumber utama obat bagi manusia sejak zaman kuno, sifat tanaman obat ini disebabkan karena adanya metabolit sekunder bioaktif yang terkandung di dalamnya [1]. Dalam dua dekade terakhir, popularitas pemakaian dan penelitian bahan baku tanaman obat untuk sistem kesehatan tradisional dan farmasi meningkat secara signifikan [2]. Menurut *World Health Organization (WHO)* hampir 70% masyarakat pada negara berkembang sangat bergantung pada sistem kesehatan tradisional untuk pengobatan berbagai penyakit termasuk negara Indonesia [3]. Sekitar seperempat dari semua obat yang sudah diproduksi dan diresepkan mengandung senyawa berasal dari tanaman sehingga banyak obat yang dikonsumsi masyarakat saat ini lebih menggunakan obat alami karena memiliki efek samping yang minimal dan lebih terjangkau harganya[4][5].

Seiring meningkatnya permintaan global akan obat herbal, banyak perusahaan dan organisasi berkompetisi untuk mencari bahan baku herbal berkualitas tinggi dan jumlah yang besar [6]. Akan tetapi, untuk mendapatkan bahan baku herbal yang berkualitas dan banyak secara manual itu sangat sulit karena membutuhkan orang yang profesional dalam bidang itu untuk klasifikasi tanaman obat itupun saja dapat salah dan memakan banyak waktu. tantangan terbesar dalam masalah ini merupakan kesamaan morfologi yang sangat mirip antar

tanaman sehingga sulit untuk diidentifikasi dengan cara konvensional.

Solusi yang menjanjikan untuk mengatasi masalah klasifikasi tanaman obat ini di masa depan adalah dengan menggunakan teknologi deep learning. Deep Learning adalah bagian dari Artificial Intelligence dimana mesin dapat belajar dari data dalam jumlah besar dan mengenali pola-pola yang kompleks yang tidak dapat dilakukan oleh manusia secara manual [7]. Model deep learning ini dapat dilatih untuk mengenali dan mengklasifikasi berbagai jenis tanaman obat dengan akurasi tinggi melalui dengan foto yang dimasukkan kedalam model neural network yaitu model seperti jaringan otak sehingga setiap pola dalam foto yang kompleks akan dapat dilihat secara detail dan disimpan [8].

Masalah yang muncul adalah model deep learning yang ada saat ini sangat banyak seperti VGG16, VGG19, ResNet50, DenseNet201, Inception, InceptionResNetV2, Xception dan MobileNetV3. Oleh karena itu, untuk memulai penelitian ini sangat susah karena tidak ada pengetahuan tentang model-model ini yang mana yang cocok digunakan dalam klasifikasi tanaman obat ini. Maka dari itu penelitian ini membantu untuk membandingkan 8 model diatas dengan 2 tipe dataset yang berbeda dimana dataset tipe 1 adalah gambar yang memiliki background putih saja dan tipe 2 adalah gambar dengan background putih dicampur dengan gambar yang memiliki background yang kompleks. Penelitian ini juga terinspirasi dengan penelitian sebelumnya yaitu milik B. Dey, J. Ferdous, R. Ahmed, and J. Hossain. Penelitian mereka membandingkan 7 model dan hasilnya dari 7 model itu yang memiliki akurasi tertinggi adalah DenseNet201 dengan 99.64% akurasi [9]. Penelitian ini juga terinspirasi dari penelitian yang dilakukan oleh Kayiram Kavitha; Prashant Sharma; Shubham Gupta; R.V.S. Lalitha. Mereka melakukan penelitian dengan membandingkan 5 model deep learning dan hasil dari 5 model tersebut, model yang memiliki akurasi tertinggi adalah InceptionV3 dengan 95.16% accuracy [12]. Yang membedakan dengan penelitian sebelumnya adalah penelitian ini menambahkan model mobileNet agar dapat dilakukan secara efisien dan juga Dataset dengan background yang kompleks ini di crop terlebih dahulu dan yang lebih beragam yang dikumpulkan sendiri melalui internet.

Untuk menghubungkan research gap ini, penelitian ini fokus pada analisis performa 8 model algoritma *deep learning* s (VGG16,VGG19, DenseNet201, InceptionV3, ResNet50V2,

Xception, InceptionResnetV2, MobileNetV3) . Model-model ini akan ditrain dengan 2 tipe dataset yaitu dengan tipe 1 adalah gambar dengan background putih dan tipe 2 gambar dengan background putih dan kompleks yang di crop. Dengan 2 tipe dataset ini akan lebih kompatibel dalam dunia nyata yang memiliki kontras dan resolusi yang beragam. 8 model ini akan dipilih sesuai dengan performa dan keberhasilan di keberagaman pengenalan foto, sehingga penelitian ini dapat membandingkan model mana yang terbaik untuk digunakan dalam komunitas lokal tanpa orang yang profesional untuk mengenali tanaman obat. Fokus permasalahan yang kami teliti adalah Apakah dapat digunakan dalam klasifikasi tanaman obat dengan menggunakan MobileNet , Berapa akurasi model MobileNet dibanding model lainnya dan Apakah kami dapat meningkatkan akurasi diatas 95% pada dataset tipe kedua.

## II. DATASET

Metode - Metode yang dipakai dalam penelitian ini adalah..

### A. Dataset

Dataset dalam penelitian ini dibagi menjadi 2 tipe pengambilan dimana tipe pertama penelitian ini menggunakan dataset gambar daun dengan background yang berwarna putih yang diambil dari kaggle yang bernama Indian Medicinal Dataset [10][11] dan tipe kedua dataset gambar daun dengan background putih dan background yang kompleks yang di crop manual dan dikumpulkan sendiri dari google,kaggle, roboflow, dan banyak lagi lalu dalam penelitian ini menguji dengan 2 tipe dataset yaitu terdiri dari 30 kelas tumbuhan dengan total 5826 gambar

TABLE I

No	Nama Tanaman	Tipe 1	Tipe 2
1	Alpinia Galanga	50	174
2	Amaranthus Viridis	122	177
3	Artocarpus Heterophyllus	56	225
4	Azadirachta Indica	60	162
5	Basella Alba	107	182
6	Brassica Juncea	34	205
7	Carissa Carandas	74	186
8	Citrus Limon	61	199
9	Ficus Auriculata	50	169
10	Ficus Religiosa	63	203
11	Hibiscus Rosa	43	212
12	Jasminum	71	226
13	Mangifera Indica	62	194

14	Mentha Piperita	97	169
15	Moringa Oleifera	77	176
16	Muntingia Calabura	56	168
17	Murraya Koenigii	60	224
18	Nerium Oleander	62	170
19	Nyctanthes Arbor Tristis	40	168
20	Ocimum Tenuiflorum	52	222
21	Piper Betle	48	272
22	Plectranthus Amboinicus	48	190
23	Pongamia Pinnata	61	212
24	Psidium Guajava	65	200
25	Punica Granatum	79	263
26	Santalum Album	58	188
27	Syzygium Cumini	39	170
28	Syzygium Jambos	56	181
29	Tabernaemontana Divaricata	56	170
30	Trigonella Foenum Graecum	36	169
	Total	1843	5826

tipe 1 = background putih & tipe 2 = background putih dan kompleks

## III.METHODS

### A. VGG16 & VGG19

Very Deep Convolutional Network (VGG) merupakan salah satu model terbaik dari Convolutional Neural Network untuk object detection dan classification algorithm dimana dapat mengklasifikasikan 1000 images dari 1000 kategori berbeda dengan 92.7% accuracy. Dimana hal ini sangat membantu untuk mengenali objek yang berbeda-beda dalam kehidupan nyata . Model VGG ini dikenal karena kesederhanaan desain yang mengandalkan susunan lapisan konvolusi 3x3 yang diikuti oleh lapisan pooling maksimal 2x2.VGG memiliki 2 tipe yang biasanya digunakan adalah VGG16 terdiri dari 16 lapisan yang dapat dilatih dan VGG19 memiliki 19 lapisan. Arsitektur ini juga menggunakan jumlah parameter yang besar dan memerlukan daya komputasi yang tinggi serta waktu pelatihan yang lama.

Kelebihan utama VGG16 dan VGG19 adalah stabilitas dan kemampuannya untuk menggeneralisasi data, yang membuatnya efektif dalam mendeteksi fitur dari data gambar yang kompleks. Namun, kekurangannya adalah ukuran model yang besar dan kebutuhan akan sumber daya

komputasi yang tinggi, yang dapat menjadi tantangan untuk implementasi di perangkat dengan kapasitas terbatas. Kedua model ini telah menjadi dasar bagi pengembangan lebih lanjut dalam arsitektur deep learning.

#### B. *ResNe50tV2*

Resnet atau disebut juga residual network yang dikenalkan oleh Kaiming He, Xiangyu Zhang, Shaoqing Ren and Jian sun pada tahun 2015 dimana merupakan model dengan 50 layer dalam deep learning untuk computer vision. Dimana kegunaannya untuk mengatasi masalah yang sering dialami saat train yaitu gradien yang hilang, yang artinya nilai absolut dari sinyal gradien cenderung menurun secara eksponensial saat kita berpindah dari lapisan terakhir ke lapisan pertama dan hal ini membuat proses penurunan gradien menjadi sangat lambat.

Resnet block memperkenalkan model dengan “skip-connection” dimana membantu kita untuk mengatasi gradien yang hilang. Cara kerjanya cukup unik dimana terdapat residual network block (convolutional block) dengan skip connection yang dapat belajar untuk identifikasi fungsi (identity block)

ResNet50V2 memperkenalkan batch normalization setelah penjumlahan shortcut, yang meningkatkan stabilitas pelatihan dan akurasi pada validasi. Arsitektur ini terkenal karena kemampuannya yang tinggi dalam mengenali pola kompleks dalam gambar sambil mempertahankan efisiensi komputasi. Hal ini menjadikannya pilihan unggul untuk berbagai aplikasi visi komputer yang membutuhkan keakuratan dan kedalaman jaringan yang mendalam.

#### C. *InceptionV3*

InceptionV3 adalah arsitektur jaringan saraf dalam yang dikembangkan oleh Google dan terkenal dengan pendekatannya yang inovatif terhadap desain jaringan. Model ini menggunakan berbagai ukuran filter dalam satu lapisan, yang dikenal sebagai "Inception module", untuk menangkap fitur pada berbagai skala. InceptionV3 terdiri dari 48 lapisan yang memungkinkan penggunaan fitur yang lebih dalam dan kompleks dengan efisiensi komputasi yang lebih baik.

Keunikan InceptionV3 terletak pada penggunaan teknik seperti factorized convolutions dan auxiliary classifiers yang membantu meningkatkan kinerja tanpa meningkatkan beban komputasi secara signifikan. Ini menjadikannya salah satu model yang paling efisien dan akurat untuk tugas-tugas klasifikasi gambar, terutama di lingkungan dengan keterbatasan sumber daya.

#### D. *InceptionResNetV2*

InceptionResNetV2 adalah kombinasi dari dua pendekatan canggih dalam deep learning: Inception module dan residual learning. Model ini menggabungkan kekuatan InceptionV3 dengan keunggulan dari residual connections untuk membangun jaringan yang sangat dalam dan efektif.

Dengan struktur yang lebih kompleks dari InceptionV3, InceptionResNetV2 mampu mengatasi masalah gradient vanishing yang sering muncul di jaringan yang lebih dalam.

Model ini memiliki kemampuan luar biasa dalam mempelajari fitur yang sangat kompleks dari data gambar, menjadikannya ideal untuk aplikasi yang membutuhkan akurasi tinggi seperti klasifikasi dan segmentasi gambar. Meskipun memerlukan sumber daya komputasi yang lebih besar, InceptionResNetV2 menawarkan peningkatan performa yang signifikan dan stabilitas yang lebih baik dibandingkan dengan model-model yang lebih sederhana.

#### E. *Xception*

Xception, yang merupakan singkatan dari “Extreme Inception,” adalah model deep learning yang dikembangkan oleh François Chollet. Model ini memperluas ide dari Inception dengan menggantikan modul Inception konvensional dengan depthwise separable convolutions, yang secara signifikan mengurangi jumlah parameter dan meningkatkan efisiensi komputasi. Xception terdiri dari 71 lapisan yang memungkinkan analisis fitur yang sangat detail dari data gambar.

Kelebihan utama Xception adalah kemampuannya untuk mempertahankan performa tinggi sambil mengurangi beban komputasi, menjadikannya ideal untuk aplikasi di perangkat yang terbatas sumber dayanya. Model ini menunjukkan hasil yang kompetitif dalam tugas-tugas klasifikasi dan segmentasi gambar, dengan keunggulan dalam generalisasi data dan penanganan fitur yang rumit.

#### F. *DenseNet201*

DenseNet201 adalah model deep learning yang diperkenalkan dengan konsep dense connectivity, di mana setiap lapisan dalam jaringan menerima input dari semua lapisan sebelumnya dan mengirimkan outputnya ke semua lapisan berikutnya. Dengan 201 lapisan, arsitektur ini memungkinkan gradien mengalir lebih baik dan meningkatkan efisiensi parameter, yang mengarah pada pelatihan yang lebih cepat dan penggunaan memori yang lebih efisien.

DenseNet201 menawarkan keuntungan signifikan dalam hal pemanfaatan ulang fitur yang ada, yang mengurangi risiko overfitting dan meningkatkan kemampuan model untuk menangani data yang kompleks. Model ini sangat efektif untuk aplikasi yang membutuhkan deteksi fitur mendetail dan generalisasi yang kuat, seperti klasifikasi gambar dan pengenalan objek.

#### G. *MobileNetV3-Large*

MobileNetV3-Large adalah versi terbaru dari seri MobileNet, yang dirancang khusus untuk efisiensi dan kecepatan di perangkat seluler dan sistem yang terbatas

sumber dayanya. Model ini menggunakan kombinasi dari squeeze-and-excitation modules, depthwise separable convolutions, dan neural architecture search untuk mengoptimalkan performa dan efisiensi.

Keunggulan utama dari MobileNetV3-Large adalah kemampuannya untuk memberikan kinerja yang tinggi dengan penggunaan daya dan memori yang minimal, menjadikannya pilihan ideal untuk aplikasi real-time seperti pengenalan gambar di perangkat seluler. Dengan desain yang efisien, model ini tetap mempertahankan akurasi yang kompetitif dibandingkan dengan model yang lebih kompleks dan besar.

## IV. EXPERIMENTAL RESULT

### A. Preprocessing Data

Setelah kami mengumpulkan dataset, hal pertama yang kami lakukan adalah menguji terlebih dahulu dataset mix dan dataset yang background kompleks dengan 8 model yang kami terapkan akan tetapi hasilnya belum memuaskan akurasi tidak meningkat dan sangat tidak bagus. Setelah kami teliti ternyata permasalahannya ada di bentuk,luas dan posisi gambar daun dimana terdapat pohonya, orang dan lain sebagainya. Maka dari itu kami terapkan crop secara manual pada bagian dataset yang memiliki background kompleks dan yang background putih kami tidak crop.

Langkah selanjutnya, kami memisahkan data untuk 2 tipe dataset menjadi 3 bagian yaitu train . test dan validation dengan perbandingan 80 : 10 : 10 dari setiap kelas. Sebelum kami train kami melakukan perubahan size menjadi 224x224 dengan channel 3 pada setiap gambar dan normalisasi RGB pada gambar menjadi antara 0 sampai 1. Langkah terakhir sebelum train dimulai kami melakukan mengubah data menjadi tensor (*load tensorflow from directory*) agar mempermudah penggunaan model yang telah disediakan oleh tensorflow.

### B. Processing Data

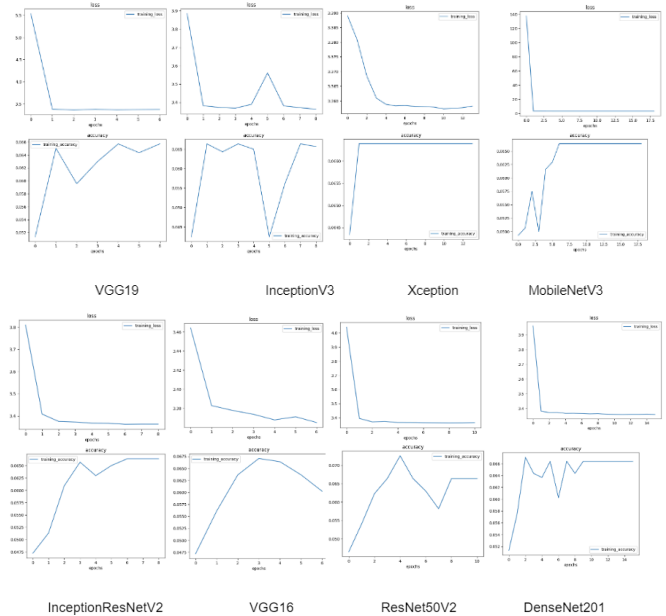
Untuk memproses dataset kami awalnya menguji terlebih dahulu dataset yang background putih saja , background kompleks saja dan background mix dengan 8 model yaitu VGG16, VGG19, DenseNet201, InceptionV3, ResNet50V2, Xception, InceptionResnetV2, dan MobileNetV3 yang kami lakukan dengan 100 epoch dan 32 batch size dan callback jika ada hasil epoch yang sama akan otomatis berhenti dengan memonitor val loss seperti yang sudah kami katakan pada bagian preprocessing akan tetapi hasil sangat tidak bagus akurasinya pada background kompleks dan background mix maka dari itu kami crop dan menggunakan dataset tipe 1 yaitu background putih dan dataset tipe 2 yaitu mix background putih dan kompleks crops.

Untuk mengujuan 2 tipa dataset ini kami juga melakukan yang dengan 8 model yaitu VGG16, VGG19, DenseNet201, InceptionV3, ResNet50V2, Xception, InceptionResnetV2, dan MobileNetV3 dengan parameter 100 epoch dan 32 batch kenapa kami menggunakan 32 batch karena dense net tidak dapat memproses

batch yang terlalu besar dan callback jika ada hasil epoch yang sama akan otomatis berhenti dengan memonitor val loss. lalu kami teliti dengan metrics akurasi, loss validation loss, validation akurasi, berapa durasi yang dibutuhkan dan berhenti di epoch ke berapa 150606 .

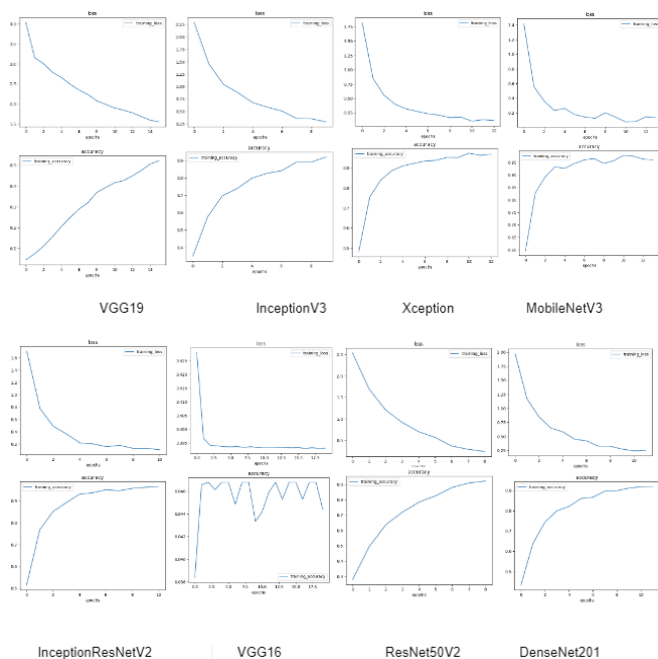
## C. Result

### a. Tipe 1



DATASET WHITE						
MODEL	Loss	Accura cy	Val_Lo ss	Val_Accu racy	Duratio n	Epoc h
VGG 16	3.365	0.06	3.351	0.069	27.73	7
VGG 19	3.378	0.066	3.361	0.069	28.39	7
Resnet50V2	3.365	0.066	3.353	0.069	28.11	11
DenseNet201	3.359	0.066	3.349	0.069	29.57	16
InceptionV3	3.362	0.066	3.353	0.069	26.66	9
Xception	3.358	0.066	3.349	0.069	26.65	14
InceptionResN etV2	3.363	0.066	3.355	0.069	28.3	9
MobileNetV3L arge	3.362	0.066	3.351	0.069	22.7	19

## b. Tipe 2



DATASET MIX						
MODEL	Loss	Accuracy	Val_Loss	Val_Accuracy	Durasi	Epoch
VGG 16	3.393	0.044	3.391	0.047	85.68	20
VGG 19	1.555	0.522	2.732	0.328	85.24	16
Resnet50V2	0.236	0.921	1.904	0.564	80.01	9
DenseNet201	0.251	0.919	1.171	0.729	91.59	12
InceptionV3	0.285	0.92	1.595	0.629	77.3	10
Xception	0.116	0.968	1.142	0.754	85.45	13
InceptionResNetV2	0.107	0.967	1.235	0.733	93.9	11
MobileNetV3Large	0.133	0.959	1.067	0.768	76.55	14

## V. CONCLUSIONS

Dari hasil train sebelumnya, didapatkan kalau model ternyata dapat bekerja jauh lebih baik dengan dataset tipe 2 dibandingkan dataset tipe 1. Hal ini cukup mengejutkan dikarenakan dataset tipe 1 adalah dataset yang sudah sangat bagus dengan gambar yang terfokus hanya 1 objek daun saja. Tetapi model masih belum bisa bekerja sesuai dengan ekspektasi awal yaitu memiliki akurasi yang lebih bagus dibandingkan model yang di train dengan dataset tipe 2. Di sisi lain, dataset tipe 2, memiliki akurasi yang jauh lebih baik

bahkan 10x lipat dibandingkan model tipe 1. Hal ini dapat terjadi karena model memiliki dataset yang cukup banyak dan juga cukup bervariasi. Model juga memiliki performa yang baik di dataset validasi dengan akurasi validasi yang paling tinggi didapatkan oleh model MobileNetV3 yang mendapatkan akurasi 76.8%. Ini membuktikan bahwa MobileNetV3 dengan arsitektur yang lebih kecil dan lebih ringan dibandingkan model - model yang ada di paper ini, memiliki kemampuan yang cukup baik untuk melakukan klasifikasi pada tanaman. Hanya saja, model - model yang ada masih belum bisa mendapatkan akurasi melebihi 95% pada dataset validasi. Hal ini berarti masih ada hal yang dapat ditingkatkan untuk penelitian kedepan seperti meningkatkan kuantitas dan kualitas dataset yang digunakan, dan metode pre-processing yang lebih baik lagi untuk penelitian kedepannya. Akan tetapi, dari hasil penelitian ini menunjukkan bahwa ada potensi dalam menggunakan bagian daun saja dari tanaman obat dalam melakukan klasifikasi dari tanaman obat yang berbeda - beda dengan menggunakan metode deep learning. Penemuan ini tentu dapat membantu industri medis dalam mengklasifikasikan tanaman obat dengan efek medis yang berbeda - beda.

## REFERENCES

- [1] R. Croteau, T. M. Kutchan, and N. G. Lewis, "Natural Products (Secondary Metabolites)," in *Biochemistry and Molecular Biology of Plants*, B. Buchanan, W. Gruissem, and R. L. Jones, Eds., Rockville, MD: American Society of Plant Physiologists, 2000, pp. 1250-1318.
- [2] L. S. Phondani, R. Prasad, and S. Bhattacharya, "Ethnobotanical review on traditional uses of medicinal plants: Where can we still learn and what can we still learn?," *Indian Journal of Traditional Knowledge*, vol. 13, no. 3, pp. 1-14, 2014.
- [3] S.M. Jeelani, G.A. Rather, A. Sharma, S.K. Lattoo, In perspective: potential medicinal plant resources of Kashmir Himalayas, their domestication and cultivation for commercial exploitation, *Journal of Applied Research on Medicinal and Aromatic Plants* 8 (2018) 10–25, <https://doi.org/10.1016/J.JARMAP.2017.11.001>.
- [4] R. Joshi, R. Joshi, and A. Joshi, "Herbal Medicine: Current Trends and Future Prospects," *Journal of Medicinal Plants Research*, vol. 3, no. 5, pp. 79-91, 2009.
- [5] U. Kala, A. Shahid, and M. Bhattacharya, "Future of Herbal Medicine: Trends and Perspectives," *Journal of Herbal Medicine*, vol. 6, no. 2, pp. 89-97, 2006.
- [6] A. Shahid, S. Bhattacharya, and R. Prasad, "Global Market for Herbal Medicines: An Overview," *Journal of Ethnopharmacology*, vol. 149, no. 2, pp. 34-42, 2013.
- [7] Y. LeCun, Y. Bengio, and G. Hinton, "Deep learning," *Nature*, vol. 521, pp. 436-444, May 2015.
- [8] A. Krizhevsky, I. Sutskever, and G. E. Hinton, "ImageNet Classification with Deep Convolutional Neural Networks," in *Proc. 25th Int. Conf. Neural Inf. Process. Syst. (NIPS)*, 2012, pp. 1097-1105.
- [9] B. Dey, J. Ferdous, R. Ahmed, and J. Hossain, "Assessing deep convolutional neural network models and their comparative performance for automated medicinal plant identification from leaf images," *\*Heliyon\**, vol. 10, no. 1, Art. no. e23655, 2024, doi: 10.1016/j.heliyon.2023.e23655.
- [10] Arya Shah, "Indian Medicinal Leaves Dataset," Kaggle, 2021. [Online]. Available: <https://www.kaggle.com/datasets/aryashah2k/indian-medicinal-leaves-dataset>. [Accessed: Jun. 15, 2024].
- [11] B. R. Pushpa and Shobha Rani, "Indian Medicinal Leaves Image Datasets," *Mendeley Data*, V3, 2023. doi: 10.17632/748f8jkphb.3.
- [12] K. Kavitha, P. Sharma, S. Gupta and R. V. S. Lalitha, "Medicinal Plant Species Detection using Deep Learning," 2022 First International Conference on Electrical, Electronics, Information and Communication

*Technologies (ICEEICT), Trichy, India, 2022, pp. 01-06, doi: 10.1109/ICEEICT53079.2022.9768649. keywords: {Training;Deep learning;Measurement;Computer vision;Computational modeling;Stochastic processes;Computer architecture;Medicinal Plant Species Detection;Inception v3;Convolution Neural Networks;stochastic gradient descent technique;Deep Learning}.*